题目1

原始数据与总体熵

编号	色泽	根蒂	敲声	纹理	好瓜
1	青绿	蜷缩	浊响	清晰	是
2	乌黑	蜷缩	沉闷	清晰	是
3	乌黑	蜷缩	浊响	清晰	是
4	青绿	硬挺	清脆	清晰	否
5	浅白	硬挺	清脆	模糊	否
6	浅白	蜷缩	浊响	模糊	否
7	青绿	稍蜷	浊响	稍糊	否
8	乌黑	稍蜷	浊响	清晰	是

好瓜 4 条，坏瓜 4 条：

$$H(D) = -\frac{4}{8}\log_2\frac{4}{8} - \frac{4}{8}\log_2\frac{4}{8} = 1$$

第一层：选择根节点（按信息增益率）

下面对四个属性分别计算信息增益和信息增益率。

纹理

取值：清晰(1,2,3,4,8)、模糊(5,6)、稍糊(7)。

- 清晰：4 是，1 否

$$H(D_{\text{清晰}}) = -\frac{4}{5}\log_2\frac{4}{5} - \frac{1}{5}\log_2\frac{1}{5} \approx 0.722$$

- 模糊：0 是，2 否，熵 0
- 稍糊：0 是，1 否，熵 0

条件熵：

$$H(D|\text{纹理}) = \frac{5}{8}\cdot 0.722 + \frac{2}{8}\cdot 0 + \frac{1}{8}\cdot 0 \approx 0.451$$

信息增益：

$$Gain(\text{纹理}) = 1 - 0.451 \approx 0.549$$

划分信息：

$$SplitInfo(\text{纹理}) = -\left(\frac{5}{8}\log_2\frac{5}{8} + \frac{2}{8}\log_2\frac{2}{8} + \frac{1}{8}\log_2\frac{1}{8}\right) \approx 1.299$$

增益率：

$$GR(\text{纹理}) \approx \frac{0.549}{1.299} \approx 0.423$$

色泽

取值：青绿(1,4,7)、乌黑(2,3,8)、浅白(5,6)。

- 青绿：1 是，2 否 → 熵约 0.918
- 乌黑：3 是，0 否 → 熵 0
- 浅白：0 是，2 否 → 熵 0

$$H(D|\text{色泽}) = \frac{3}{8} \cdot 0.918 \approx 0.344$$

$$Gain(\text{色泽}) = 1 - 0.344 \approx 0.656$$

划分信息（3/8,3/8,2/8）：

$$SplitInfo(\text{色泽}) \approx 1.561$$

$$GR(\text{色泽}) \approx \frac{0.656}{1.561} \approx 0.420$$

根蒂

取值：蜷缩(1,2,3,6)、稍蜷(7,8)、硬挺(4,5)。

- 蜷缩：3 是，1 否 → 熵约 0.811
- 稍蜷：1 是，1 否 → 熵 1
- 硬挺：0 是，2 否 → 熵 0

$$H(D|\text{根蒂}) = \frac{4}{8} \cdot 0.811 + \frac{2}{8} \cdot 1 \approx 0.656$$

$$Gain(\text{根蒂}) = 1 - 0.656 \approx 0.344$$

划分信息（4/8,2/8,2/8）：

$$SplitInfo(\text{根蒂}) = 1.5$$

$$GR(\text{根蒂}) \approx \frac{0.344}{1.5} \approx 0.229$$

敲声

取值：浊响(1,3,6,7,8)、沉闷(2)、清脆(4,5)。

- 浊响：3 是，2 否 → 熵约 0.971
- 沉闷：1 是，0 否 → 熵 0
- 清脆：0 是，2 否 → 熵 0

$$H(D|\text{敲声}) = \frac{5}{8} \cdot 0.971 \approx 0.607$$

$$Gain(\text{敲声}) = 1 - 0.607 \approx 0.393$$

划分信息（5/8,1/8,2/8）：

$$SplitInfo(\text{敲声}) \approx 1.299$$

$$GR(\text{敲声}) \approx \frac{0.393}{1.299} \approx 0.303$$

2.5 根节点的选择

四个属性信息增益率比较：

- $(GR(\text{纹理}) \approx 0.423)$
- $(GR(\text{色泽}) \approx 0.420)$
- $(GR(\text{敲声}) \approx 0.303)$
- $(GR(\text{根蒂}) \approx 0.229)$

最大的是 **纹理**，所以根节点选 **纹理**。

第二层：在各子节点上继续划分

根节点“纹理”有三个分支。

纹理 = 模糊

样本：5、6，都是 “否”，熵为 0，直接作为叶节点：
纹理=模糊 → 否

纹理 = 稍糊

样本：7，一条，为 “否”，也直接变成叶节点：
纹理=稍糊 → 否

纹理 = 清晰

样本：1、2、3、4、8：

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	沉闷	是
3	乌黑	蜷缩	浊响	是
4	青绿	硬挺	清脆	否
8	乌黑	稍蜷	浊响	是

此时好瓜 4，坏瓜 1：

$$H(D_{\text{清晰}}) \approx 0.722$$

在这个子集上再比较剩余三个属性（色泽、根蒂、敲声）的增益率。

根蒂（在清晰子集内）

- 蜷缩：1,2,3 → 全是 “是”，熵 0
- 稍蜷：8 → “是”，熵 0
- 硬挺：4 → “否”，熵 0

条件熵为 0：

$$Gain_{清晰}(根蒂) = 0.722 - 0 = 0.722$$

划分信息：子集大小 3,1,1，得到

$$SplitInfo_{清晰}(根蒂) \approx 1.37$$

$$GR_{清晰}(根蒂) \approx \frac{0.722}{1.37} \approx 0.53$$

敲声（在清晰子集内）

浊响：1,3,8（都是 “是”），沉闷：2（是），清脆：4（否），同样每个分支纯，
所以信息增益也是 0.722，划分信息和根蒂一样，也是约 1.37，
因此增益率和根蒂相同，约 **0.53**。

色泽（在清晰子集内）

- 青绿：1,4 → 1 是，1 否，熵 1
- 乌黑：2,3,8 → 全是 “是”，熵 0

$$H(D_{清晰}|色泽) = \frac{2}{5} \cdot 1 + \frac{3}{5} \cdot 0 = 0.4$$

$$Gain_{清晰}(色泽) = 0.722 - 0.4 = 0.322$$

其增益率明显小于根蒂/敲声，这里不选。

在根蒂和敲声之间，二者效果完全一样，任选其一即可。下面用 **根蒂** 来划分，决策树形状比较直观。

于是，在“纹理=清晰”这个结点上继续按“根蒂”划分：

- 清晰 且 根蒂=蜷缩 → 样本 {1,2,3}，全为 是 → 叶节点“是”
- 清晰 且 根蒂=稍蜷 → 样本 {8}，为 是 → 叶节点“是”
- 清晰 且 根蒂=硬挺 → 样本 {4}，为 否 → 叶节点“否”

至此所有叶子都是纯的，可以停止。

最终决策树

```
                    纹理
        ┌──────────┼──────────┐
      模糊          清晰          稍糊
      否        （继续按根蒂划分）    否
                     │
                    根蒂
        ┌──────────┼──────────┐
      蜷缩          稍蜷          硬挺
       是           是           否
```

1. 若纹理 = 模糊，则判为 **否**；
2. 若纹理 = 稍糊，则判为 **否**；

3. 若纹理 = 清晰 且 根蒂 ≠ 硬挺，则判为 **是**；
4. 若纹理 = 清晰 且 根蒂 = 硬挺，则判为 **否**。

题目2

计算与各训练样本的欧式距离

编号	$((x_1, x_2))$	类别
1	(1,1)	A
2	(2,1)	A
3	(4,3)	A
4	(5,4)	B
5	(6,5)	B
6	(7,3)	B

欧式距离公式：

$$d\big((x_1, x_2), (4, 2.5)\big) = \sqrt{(x_1 - 4)^2 + (x_2 - 2.5)^2}$$

逐个计算（保留两位小数）：

1. 编号1:

$$d_1 = \sqrt{(1-4)^2 + (1-2.5)^2} = \sqrt{9 + 2.25} \approx 3.35$$

2. 编号2:

$$d_2 = \sqrt{(2-4)^2 + (1-2.5)^2} = \sqrt{4 + 2.25} = 2.50$$

3. 编号3:

$$d_3 = \sqrt{(4-4)^2 + (3-2.5)^2} = \sqrt{0 + 0.25} = 0.50$$

4. 编号4:

$$d_4 = \sqrt{(5-4)^2 + (4-2.5)^2} = \sqrt{1 + 2.25} \approx 1.80$$

5. 编号5:

$$d_5 = \sqrt{(6-4)^2 + (5-2.5)^2} = \sqrt{4 + 6.25} \approx 3.20$$

6. 编号6:

$$d_6 = \sqrt{(7-4)^2 + (3-2.5)^2} = \sqrt{9 + 0.25} \approx 3.04$$

按距离从小到大排序：

排名	编号	距离	类别
1	3	0.50	A
2	4	1.80	B
3	2	2.50	A
4	6	3.04	B
5	5	3.20	B
6	1	3.35	A

取最近的 k=3 个邻居

最近的 3 个样本：编号 3（A），4（B），2（A）。
其中 A 类 2 个，B 类 1 个。

分类结果

按照多数表决原则，测试样本$(x = (4, 2.5))$ 被判为：

$$\boxed{\text{A 类}}$$

题目3

训练集：

序号	x	y
1	1	+1
2	2	+1
3	3	+1
4	4	−1
5	5	−1
6	6	−1

弱分类器形式

$$h(x) = \{+1, \quad x \le \theta \ -1, \quad x > \theta, \qquad \theta \in 2.5, 4.5, 5.5$$

第一轮

初始权重

$$w_i^{(1)} = \frac{1}{6}, \quad i = 1, \ldots, 6$$

计算三个阈值的加权错误率

- **θ = 2.5**

  (x>2.5) 时判为 −1。
  错误样本：3 号（3, +1）

$$(\varepsilon_1(2.5) = w_3^{(1)} = \frac{1}{6})$$

- **θ = 4.5**

  错误样本：4 号（4, −1）

$$(\varepsilon_1(4.5) = w_4^{(1)} = \frac{1}{6})$$

- **θ = 5.5**

  错误样本：4、5 号

$$(\varepsilon_1(5.5) = w_4^{(1)} + w_5^{(1)} = \frac{2}{6} = \frac{1}{3})$$

错误率最小的是 θ=2.5 和 θ=4.5（都为 1/6），任选其一即可。下面取

$$h_1(x) = h(x; \theta_1 = 2.5)$$

此时

$$\varepsilon_1 = \frac{1}{6}$$

弱分类器权重

$$\alpha_1 = \frac{1}{2}\ln\frac{1-\varepsilon_1}{\varepsilon_1} = \frac{1}{2}\ln\frac{5/6}{1/6} = \frac{1}{2}\ln 5$$

更新样本权重

被正确分类的样本：1,2,4,5,6
被误分类的样本：3

更新公式：

$$w_i^{(2)} \propto w_i^{(1)} \exp\left(-\alpha_1 y_i h_1(x_i)\right)$$

对正确样本有$(y_i h_1(x_i) = +1)$，权重乘$(\exp\left(-\alpha_1\right))$；
对错误样本有$(y_i h_1(x_i) = -1)$，权重乘$(\exp\left(\alpha_1\right))$。

又因为

$$\exp\left(2\alpha_1\right) = \frac{1-\varepsilon_1}{\varepsilon_1} = 5$$

因此**误分类样本的权重是正确样本的 5 倍**。归一化后得到：

$$w_3^{(2)} = \frac{1}{2}, \quad w_1^{(2)} = w_2^{(2)} = w_4^{(2)} = w_5^{(2)} = w_6^{(2)} = \frac{1}{10}$$

第二轮

在新的权重分布$(w^{(2)})$下再选弱分类器。

计算新的加权错误率

- **θ = 2.5**

  仍然只错样本 3

$$(\varepsilon_2(2.5) = w_3^{(2)} = \frac{1}{2})$$

- **θ = 4.5**

  错误样本：4 号

$$(\varepsilon_2(4.5) = w_4^{(2)} = \frac{1}{10})$$

- **θ = 5.5**

  错误样本：4、5 号

$$(\varepsilon_2(5.5) = w_4^{(2)} + w_5^{(2)} = \frac{2}{10} = 0.2)$$

因此最优弱分类器为

$$h_2(x) = h(x; \theta_2 = 4.5), \qquad \varepsilon_2 = 0.1$$

对应的权重

$$\alpha_2 = \frac{1}{2}\ln\frac{1-\varepsilon_2}{\varepsilon_2} = \frac{1}{2}\ln\frac{0.9}{0.1} = \frac{1}{2}\ln 9$$

强分类器及$(x_{\text{test}} = 3.5)$的分类结果

两轮 AdaBoost 的强分类器为

$$H(x) = \text{sign}\left(\alpha_1 h_1(x) + \alpha_2 h_2(x)\right)\text{其中}(h_1(x) = h(x; 2.5))，(h_2(x) = h(x; 4.5))。$$

对测试点$(x_{\text{test}} = 3.5)$:

$$h_1(3.5) = \{+1, \quad 3.5 \le 2.5 \ -1, \quad 3.5 > 2.5 = -1$$

$$h_2(3.5) = \{+1, \quad 3.5 \le 4.5 \ -1, \quad 3.5 > 4.5 = +1$$

因此

$$\alpha_1 h_1(3.5) + \alpha_2 h_2(3.5) = -\alpha_1 + \alpha_2 = \frac{1}{2}(\ln 9 - \ln 5) > 0$$

$$H(3.5) = +1$$

最终结果：测试样本$(x_{\text{test}} = 3.5)$被强分类器判为类别 (+1)。